

Capacidad y límites de modelos tipo CLIP para el análisis de información gráfica en documentos financieros

Oscar Benito Toledo Guerrero

MCC225 — IA Generativa y Aprendizaje Multimodal — Período 2026-1

Repositorio: https://github.com/tgoscar/evaluacion_mcc225 — tag final-mcc225

1. Problema, modalidades y pregunta experimental

Los informes de estabilidad financiera comunican buena parte de su contenido en gráficos: ratios de capital, curvas de morosidad, mapas de vulnerabilidad y proyecciones de estrés. Antes de plantear cualquier automatización sobre estos documentos hay que responder una pregunta previa y mucho más modesta: ¿un modelo visión-lenguaje distingue siquiera un gráfico financiero de otro?

El problema es multimodal porque la unidad de análisis es un par **imagen-texto**: la imagen aporta la estructura visual (forma de las series, altura relativa de las barras, codificación por color) y el texto aporta la descripción en lenguaje natural. Ninguna de las dos modalidades resuelve la tarea por separado, y la salida esperada es un emparejamiento entre ambas.

Pregunta experimental. LongCLIP amplía la ventana de contexto de CLIP de 77 a 248 tokens conservando el mismo encoder visual. Si un caption largo describe mejor un gráfico, LongCLIP debería superar a CLIP-L. La pregunta, falsable, es:

Al recuperar el caption correcto de un gráfico financiero, ¿la ventaja de LongCLIP proviene de su ventana de contexto o del encoder visual?

Se rechazaría la hipótesis del contexto si la ventaja de LongCLIP fuera similar con captions cortos y largos, o si desapareciera al controlar el encoder.

2. Línea base, modelo principal y diseño experimental

Los tres modelos comparten arquitectura de *dual encoder* contrastivo y se usan *zero-shot*, sin ajuste fino. Su encoder visual es un **Vision Transformer (ViT)**, arquitectura introducida por Dosovitskiy et al. en Google Research [1], que divide la imagen en parches cuadrados de tamaño fijo y los trata como una secuencia de *tokens* visuales, igual que un Transformer de texto trata las palabras. La notación ViT-B/32 indica tamaño *Base* y parches de 32×32 píxeles; ViT-L/14, tamaño *Large* y parches de 14×14 . CLIP fue desarrollado por OpenAI [2] y LongCLIP es una extensión posterior que amplía sus embeddings posicionales de texto [3]. El diseño separa dos variables que en una comparación directa quedarían confundidas:

Modelo	Encoder visual	Parches (224×224)	Tokens
CLIP-B (línea base)	ViT-B/32	49	77
CLIP-L (puente)	ViT-L/14	256	77
LongCLIP	ViT-L/14	256	248

efecto de tamaño = CLIP-L – CLIP-B, efecto de contexto = LongCLIP – CLIP-L

CLIP-B y CLIP-L comparten el límite de 77 tokens, de modo que su diferencia aísla el encoder; CLIP-L y LongCLIP comparten el ViT-L/14, de modo que su diferencia aísla la ventana. Comparar CLIP-B con LongCLIP no separaría nada, porque cambian ambas cosas a la vez.

Como control de robustez se evalúan **baselines con captions desplazados** una posición, que deben rendir cerca del azar.

3. Dataset, particiones, métricas y configuración

Dataset. 95 gráficos extraídos de tres ediciones del Informe de Estabilidad del Sistema Financiero de la SBS: mayo 2021 (26), noviembre 2024 (29) y mayo 2026 (40). Documentos públicos, uso académico. Cada gráfico se recorta automáticamente de su página (PyMuPDF, 170 DPI) y lleva cuatro captions: **caption_2** es el título; **caption_3** añade la oración literal del informe que comenta el gráfico; **caption_4** es una descripción de la *forma* del gráfico —tipo, paneles, ejes, series y trayectorias— generada con un modelo visión-lenguaje sobre cada imagen. Los tres se distinguen por lo que describen, no solo por su longitud: los dos primeros hablan del contexto económico y el tercero del contenido visual. El manifiesto registra procedencia (página del PDF), edición y **fFuente_oracion**.

Particiones. Cada edición se evalúa como un **pool de recuperación independiente**. No se mezclan las 95 imágenes en una sola matriz por dos razones: el R@1 depende del número de distractores, de modo que un pool de 95 no sería comparable con el de 40; y tres títulos se repiten entre ediciones (“Crecimiento económico global” aparece en 2021 y 2024), lo que dejaría pares sin respuesta correcta única. Cada edición actúa así como una réplica independiente del mismo experimento.

Métricas. R@1 y R@5 miden si el caption correcto queda entre los primeros; MRR usa la posición completa del ranking. Las dos familias no son redundantes: con CLIP-L, `caption_2` y `caption_3` empatan en R@1 (0.650) y difieren en MRR (0.716 frente a 0.748), porque MRR premia dejar el correcto cerca del tope aunque no gane.

Configuración. Semilla 22514, decodificación determinista, rutas relativas. Checkpoints: `openai/clip-vit-base-patch32`, `openai/clip-vit-large-patch14` y `zer0int/LongCLIP-GmP-ViT-L-14`. Para LongCLIP se amplía `max_position_embeddings` a 248 *antes* de cargar los pesos y se verifica con `assert`; sin ese paso el modelo se instancia con 77 posiciones y la variable central del estudio no se activaría. Todo queda registrado en `results/configuracion_experimental.json`.

4. Resultados principales

Table 1: i2t R@1 y MRR, promedio ponderado sobre las tres ediciones ($n = 95$). La ablación elimina la franja del título impreso de cada imagen. `caption_2` es el título; `caption_3` añade la oración del informe; `caption_4` describe el gráfico (tipo, series, ejes, trayectorias), con una mediana de 212 tokens. En negrita, el mejor caption de cada modelo sin el título impreso.

Modelo	Caption	Originales	Sin título impreso	
		R@1	R@1	MRR
CLIP-B	<code>caption_2</code>	0.400	0.211	0.327
CLIP-B	<code>caption_3</code>	0.474	0.253	0.369
CLIP-B	<code>caption_4</code>	0.484	0.316	0.449
CLIP-L	<code>caption_2</code>	0.684	0.326	0.448
CLIP-L	<code>caption_3</code>	0.632	0.337	0.487
CLIP-L	<code>caption_4</code>	0.632	0.390	0.531
LongCLIP	<code>caption_2</code>	0.600	0.232	0.369
LongCLIP	<code>caption_3</code>	0.642	0.242	0.413
LongCLIP	<code>caption_4</code>	0.611	0.358	0.506
<i>Baseline desplazado</i>		0.000–0.138 según edición		




Figure 1: Efecto de eliminar el título impreso. La línea punteada marca el azar (≈ 0.03). Cerca de la mitad del desempeño desaparece, pero lo que queda sigue siendo un orden de magnitud superior al azar. Nótese el cambio de orden: con el título gana `caption_2` en CLIP-L, y sin él gana `caption_4` en los tres modelos.

Estabilidad. Con $n = 40$ el IC95 bootstrap del R@1 es ± 0.148 ; al ampliar a 95 baja a ± 0.096 . Como los tres modelos ven los mismos gráficos, las diferencias se contrastan con la prueba pareada de McNemar:

Comparación	Originales		Sin título	
	discordancias	p	discordancias	p
Efecto de tamaño (B→L)	5 / 32	< 0.0001	9 / 20	0.061
Efecto de contexto, caption corto	17 / 9	0.169	13 / 4	0.049
Efecto de contexto, caption largo	15 / 13	0.851	9 / 7	0.804

Discordancias leídas como solo_1 / solo_2. En el efecto de tamaño el saldo favorece a CLIP-L; en las cuatro comparaciones de contexto también favorece a CLIP-L, es decir, en sentido contrario al que la hipótesis inicial esperaba de LongCLIP.

Truncación. Con 77 tokens se trunca el 3.2 % de los `caption_2`, el 89.5 % de los `caption_3` (mediana 118 tokens) y el 88.4 % de los `caption_4` (mediana 212). LongCLIP trunca el 2.1 % y el 10.5 % respectivamente: es la primera vez que sus 248 tokens también se quedan cortos, en diez de los captions descriptivos.

La relación con el rendimiento es consistente en todos los casos: sin título y con `caption_4`, CLIP-L acierta 0.455 sobre los once no truncados y 0.238 sobre los 84 truncados. Aun así, y aun recibiendo el texto completo donde los demás reciben texto cortado, LongCLIP no supera a CLIP-L: es la evidencia más directa de que la ventana de contexto no es el cuello de botella.

Respuesta a la pregunta experimental. El efecto de contexto no se sostiene. Con las imágenes originales no es distinguible del ruido ($p = 0.169$ y $p = 0.851$), y sin el título el saldo de discordancias se inclina hacia CLIP-L en las tres comparaciones, de modo que no se trata de falta de datos. La ganancia atribuible a los 248 tokens no aparece en ninguna condición.

Un matiz que cambia la lectura sobre los captions largos. Al reemplazar `caption_4` por una descripción del contenido visual del gráfico —en lugar de una condensación del texto del informe— el caption largo pasa a ser el mejor de los tres, pero *solo* cuando se quita el título impreso: CLIP-L sube de 0.326 con el título a 0.390, LongCLIP de 0.232 a 0.358 y CLIP-B de 0.211 a 0.316. Con las imágenes originales no gana, porque el atajo del título ya resuelve la tarea.

La ganancia respecto del título es mayor en LongCLIP (+0.126) que en CLIP-L (+0.063), coherente con que CLIP trunca el 88.4 % de estos captions y LongCLIP solo el 10.5 %. Aun así LongCLIP no supera a CLIP-L en absoluto (0.358 frente a 0.390): la ventana larga ayuda a aprovechar un caption descriptivo, pero no compensa la diferencia de encoder visual.

5. Aciertos, errores y caso ambiguo

Tipo	Gráfico	Observación
Acierto	II.1	Los tres modelos lo recuperan con los tres captions. Series divergentes y estructura de dos paneles visualmente distintiva.
Acierto	V.6	Etiquetas numéricas grandes y paleta característica; ningún otro gráfico del pool comparte esa disposición.
Error	IV.A.5	Ningún modelo lo recupera nunca. Comparte capítulo, paleta y vocabulario con IV.A.4 y IV.A.6: negativo difícil del propio pool.
Error	IV.B.4	Igual patrón dentro del bloque empresarial minorista.
Ambiguo	II.4	Con solo el título ningún modelo acierta; al añadir la oración con cifras, sí. El título no basta y la identificación depende de los datos.

Los casos de título insuficiente (II.4, IV.A.2, VI.C.1) están en `results/casos_titulo_insuficiente.csv` y los cinco analizados en `results/casos_analizados.csv`.

6. Ablaciones y comparaciones controladas

Se aplicaron tres controles, siguiendo en el segundo la metodología de Winoground [4], cada uno diseñado para eliminar un atajo distinto que el modelo podría estar usando en lugar de leer el gráfico, más una comparación adicional que probó el límite de los datos.

(1) Ablación del título impreso. Los gráficos llevan su título dentro de la imagen, y los captions contienen ese mismo título. Al recortar la franja, el R@1 de CLIP-L cae de 0.684 a 0.326 y el de LongCLIP de 0.642 a 0.242: entre la mitad y el 62 % del desempeño era coincidencia entre texto impreso y texto del caption. El efecto de tamaño pierde significancia en el proceso ($p < 0.0001 \rightarrow p = 0.061$), lo que sugiere que parte de la ventaja de ViT-L/14 era capacidad de leer texto pequeño, coherente con sus 256 parches frente a 49. Como contrapartida, el ordenamiento se vuelve más estable: CLIP-L gana en 8 de 9 combinaciones, mientras que con las imágenes originales el ganador cambiaba según la edición.

(2) Prueba composicional (Winoground). Sobre 12 pares contruidos con gráficos del IESF, con captions de estructura paralela y relaciones alteradas, se calcularon las tres señales del benchmark: *image score* (cada imagen prefiere su caption), *text score* (cada caption prefiere su imagen) y *group score* (ambas condiciones a la vez).

Modelo	Originales			Sin título		
	Image	Text	Group	Image	Text	Group
CLIP-B	0.225	0.175	0.125	0.200	0.025	0.000
CLIP-L	0.300	0.175	0.075	0.175	0.100	0.025
LongCLIP	0.550	0.250	0.175	0.150	0.175	0.075
<i>Azar</i>	<i>0.500</i>	<i>0.500</i>	<i>0.250</i>	<i>0.500</i>	<i>0.500</i>	<i>0.250</i>

Los 40 pares aplican la restricción del benchmark original: las dos opciones contienen *exactamente las mismas palabras* y solo cambia la asignación de cada término a su rol, de modo que la coincidencia léxica deja de discriminar. Frente a los 12 pares contruidos a mano de una versión anterior, ampliar la muestra estrecha el intervalo del azar de [0.005, 0.495] a [0.116, 0.384] y vuelve interpretable el resultado.

Ningún modelo alcanza el azar en group score en ninguna de las dos variantes. Sin el título el resultado es

además **significativamente inferior** al azar: obtener 0 aciertos de 40 cuando se esperan 10 tiene probabilidad $p \approx 10^{-5}$. No es ruido, sino preferencia sistemática por la opción incorrecta.

La matriz de similitudes explica por qué. En un caso representativo las diferencias *dentro* de cada fila —la señal que el benchmark mide— son de 0.006 y 0.010, mientras que la diferencia *entre* filas es de 0.080: el sesgo por imagen es trece veces mayor que la señal por caption, de modo que ambas filas terminan prefiriendo el mismo caption y el image score se anula por construcción. Los márgenes medios lo confirman: 0.003 a 0.013 con el título y 0.002 a 0.005 sin él, sobre similitudes que rondan 0.25.

El único valor que supera el azar en toda la tabla es el image score de LongCLIP con las imágenes originales (0.550), y desaparece al quitar el título (0.150). Es decir, ese acierto también dependía del texto impreso.

Aparece además una **disociación** entre las dos capacidades: CLIP-L es el mejor modelo en recuperación ($R@1 = 0.684$) y de los peores en composición. Identificar un gráfico y leer las relaciones que contiene resultan capacidades separadas.

(3) Distractores duros. El tercer control restringe el pool a gráficos de la misma sección del informe, que comparten tema, vocabulario y estilo visual. Para que la comparación sea válida, cada pool duro se contrasta con un pool *aleatorio del mismo tamaño* formado con gráficos de otras secciones: de lo contrario la mejora vendría solo de tener menos candidatos. Los pools aleatorios se repiten 20 veces por ítem ($n = 83$ ítems en secciones de al menos cuatro gráficos, pools de 4 a 13 candidatos).

Modelo	Caption	Originales			Sin título		
		duro	aleat.	caída	duro	aleat.	caída
CLIP-B	caption_2	0.518	0.598	−13.4%	0.289	0.322	−10.1%
CLIP-B	caption_3	0.627	0.709	−11.6%	0.349	0.377	−7.2%
CLIP-L	caption_2	0.723	0.803	−10.0%	0.446	0.470	−5.1%
CLIP-L	caption_3	0.711	0.877	−18.9%	0.470	0.620	−24.2%
LongCLIP	caption_2	0.651	0.728	−10.7%	0.386	0.455	−15.2%
LongCLIP	caption_3	0.711	0.858	−17.1%	0.398	0.533	−25.4%

El hallazgo no está en la caída global, que es moderada, sino en *qué* captions caen, y el patrón se repite en las dos variantes: **caption_3** pierde entre dos y cinco veces más que **caption_2**. Medido como ventaja del caption largo sobre el corto, en CLIP-L pasa de +0.074 en el pool aleatorio a −0.012 en el duro con las imágenes originales, y de +0.150 a +0.024 sin título. En LongCLIP, de +0.130 a +0.060 y de +0.078 a +0.012.

Esto identifica el mecanismo: lo que **caption_3** aportaba era **vocabulario temático del informe, no descripción del gráfico**. En un pool variado ese vocabulario discrimina; en uno del mismo capítulo los distractores lo comparten y la información extra deja de servir. Es coherente con el resultado anterior: al cambiar **caption_4** por una descripción del contenido visual, el caption largo sí aporta, porque describe algo que los distractores del mismo capítulo no comparten.

Con las imágenes originales tres de seis comparaciones alcanzan significancia (CLIP-L con **caption_2**, $p = 0.039$; CLIP-L con **caption_3**, $p = 0.0005$; LongCLIP con **caption_3**, $p = 0.001$); sin título, solo CLIP-L con **caption_3** ($p = 0.023$).

(4) Reranking en dos etapas. Siguiendo el Cuaderno 6 del curso, se entrenaron dos cabezas sobre rasgos congelados de CLIP-L —una sobre el vector agrupado y otra con atención cruzada sobre los 256 parches— con negativos semi-duros y validación dejando una edición fuera. Ambas empeoran el ranking, y por mucho:

	Originales			Sin título		
	R@1	R@5	MRR	R@1	R@5	MRR
bi-encoder	0.638	0.872	0.747	0.330	0.617	0.477
reranker <i>pooled</i>	0.213	0.638	0.413	0.149	0.511	0.308
reranker <i>patches</i>	0.117	0.628	0.340	0.160	0.564	0.328

Quedan apenas por encima de reordenar el top-10 al azar (≈ 0.075). Con 69 imágenes de entrenamiento por pliegue no es viable aprender un cross-encoder: el resultado identifica un límite de datos, no una propiedad de la arquitectura. Un detalle que conviene no sobreinterpretar: con el título la cabeza sobre el vector agrupado casi duplica a la de parches (0.213 frente a 0.117) y sin título el orden se invierte (0.149 frente a 0.160, con la de parches igual o mejor en los tres pliegues). Sería compatible con que la señal útil cambie de naturaleza —léxica cuando el título está presente, espacial cuando no—, pero ambas cabezas fallan lo suficiente como para que la diferencia no sostenga esa lectura.

7. Limitaciones y amenazas a la validez

Captions derivados del mismo informe. Los **caption_3** y **caption_4** son texto literal de la SBS que rodea al gráfico, de modo que comparten vocabulario técnico y a veces las mismas cifras impresas en la imagen. El modelo puede emparejar por coincidencia léxica y no por lectura visual, lo que probablemente infla todos los resultados. La ablación del título mide una parte de ese efecto pero no lo elimina.

Cambio de convención entre ediciones. Desde 2026 la SBS cita los gráficos explícitamente en el cuerpo del texto; en 2021 y 2024 los inserta sin citarlos. Los captions largos de las tres ediciones no se construyen, por tanto, de forma idéntica. Se controla comparando modelos *dentro* de cada edición, donde la fuente es constante para los tres, y registrando la procedencia en `fuentes_oracion`.

Tamaño y poder estadístico. Los pools son de 26 a 40 candidatos y la prueba composicional usa 12 pares, con un IC95 alrededor del azar que va de 0.005 a 0.495: ese resultado es indicativo y no permite afirmar una propiedad del modelo por sí solo. En el control con distractores duros solo una de seis comparaciones alcanza significancia, de modo que el patrón observado es consistente pero no concluyente. El resultado por debajo del azar en la prueba composicional con 40 pares es sólido estadísticamente, pero sus captions son plantillas construidas y no descripciones naturales: miden si el modelo enlaza términos con roles, no si lee relaciones visuales del tipo “la serie verde por encima de la azul”. La hipótesis del sesgo por posición del último término queda pendiente de verificación directa. Agrupar por sección del informe es además una aproximación al tema —dos gráficos de la misma sección pueden ser visualmente muy distintos—, lo que hace de ese control una medida conservadora.

Baselines elevados. En 2024-2 el baseline desplazado llega a 0.138 con `caption_2`: sin título, los gráficos de esa edición se parecen entre sí y el desplazamiento circular deja pares plausibles. El R@1 de esa edición debe leerse contra ese piso, no contra 0.03.

caption_4 es texto generado, no observado. A diferencia de los otros dos, que provienen del informe, las descripciones visuales las produce un modelo mirando cada imagen. Pueden contener errores de lectura del propio generador, y si este comparte familia o datos de entrenamiento con el modelo evaluado, el emparejamiento podría favorecerse por afinidad entre modelos más que por calidad de la descripción. El hallazgo sobre captions descriptivos debe leerse con esa reserva.

Alcance declarado. El trabajo evalúa *retrieval* y, como descubrimiento, *OCR*; mide negativamente la lectura de tendencias y no evalúa VQA financiero, que está fuera del alcance de un dual encoder.

Trabajo futuro. Verificar la hipótesis del sesgo posicional invirtiendo el orden de los términos en las plantillas: si los scores cruzan por encima del azar, el fallo es de enlace posicional y no de composición. Un reranker sin entrenamiento por interacción tardía sobre parches, que evita el límite de datos. Y comparar ViT-B/32 con ViT-B/16 para separar el tamaño de parche de la capacidad del modelo.

8. Relación con los temas de MCC225

Fundamentos. El sistema usa *fusión tardía*: imagen y texto se codifican por separado y solo se encuentran al calcular la similitud coseno. Esa elección arquitectónica define el alcance del trabajo, porque cuando el modelo ve el texto ya comprimió la imagen en un vector único.

Alineamiento. Aprendizaje contrastivo, dual encoders, zero-shot, retrieval, $R@K$ y MRR . Los *negativos difíciles* aparecen en tres formas documentadas: gráficos del mismo capítulo, títulos repetidos entre ediciones y paneles hermanos.

Transformers y VLM. El *tamaño de patch* explica el resultado principal: ViT-L/14 genera 256 parches contra 49 de ViT-B/32, cinco veces más detalle espacial, decisivo cuando la información distintiva está en etiquetas de eje pequeñas. La *atención cruzada* se implementa en el reranker de parches.

Generación grounded. Trazabilidad de evidencia: cada caption está anclado a su página, edición y fuente de la oración. La alucinación no aplica, porque un dual encoder elige entre candidatos y no genera texto.

Evaluación. *Winoground* y composicionalidad, *robustez* (baselines desplazados y distractores duros), *análisis de error y confiabilidad* (bootstrap y prueba pareada de McNemar).

Ingeniería experimental. Semillas, metadatos, tests de integridad del dataset, rutas relativas y salidas auditables en CSV y JSON.

No cubierto, declarado. Adaptación eficiente (el diseño es deliberadamente zero-shot), audio y video, y agentes.

Referencias

- [1] A. Dosovitskiy et al., *An Image Is Worth 16x16 Words: Transformers for Image Recognition at Scale*, ICLR 2021. Google Research.
- [2] A. Radford et al., *Learning Transferable Visual Models From Natural Language Supervision*, ICML 2021. OpenAI.
- [3] B. Zhang et al., *Long-CLIP: Unlocking the Long-Text Capability of CLIP*, ECCV 2024.
- [4] T. Thrush et al., *Winoground: Probing Vision and Language Models for Visio-Linguistic Compositionality*, CVPR 2022.

Reproducción. `pip install -r requirements.txt`; ejecutar los notebooks 01 a 06 en orden. Los notebooks 01 y 02 no requieren GPU y regeneran todas las tablas de este informe. Datos: SBS, Informe de Estabilidad del Sistema Financiero (2021-I, 2024-II, 2026-I), documentos públicos de uso académico.